

09 | 安全基石（上）：用权限控制与沙箱为AI戴上“安全镣铐”

Tony Bai · AI原生开发 workflow 实战



你好，我是 Tony Bai。

欢迎来到我们专栏的进阶篇。从这一讲开始，我们将从“如何使用 AI”，迈向“如何驾驭 AI”的更高阶领域。

在前面的基础篇，我们已经为 AI 伙伴装备了“眼睛”（上下文注入）、“长期记忆”

（`CLAUDE.md`）和“快捷指令”（Slash Commands）。现在，它已经非常聪明，并且蓄势待发。但随之而来的，是一个所有严肃工程师都必须面对的灵魂拷问：**我真的能信任一个 AI，让它在我的电脑上、在我的项目里，自由地读写文件、执行命令吗？**

如果它误解了我的指令“清理一下临时文件”，而去执行了 `rm -rf /` 怎么办？如果它在分析代码时不小心读取了 `.env` 文件，并将我的生产环境密钥泄露到它的训练数据中怎么办？这些合理的担忧，正是阻碍许多开发者将 AI Agent 从一个“有趣的玩具”升级为“核心生产力工具”的最后一道心理防线。

今天这一讲，我们的核心目标，就是彻底拆除这道防线。我们将深入 Claude Code 设计的“安全哲学”，系统性地学习如何为这个强大的 AI Agent，戴上一副量身定制、坚不可摧的“安全镣铐”——那就是其精密的**权限体系（Permissions）**和强大的**沙箱机制（Sandboxing）**。学完之后，你将有足够的信心和能力，去构建一个既强大又绝对可控的 AI 原生开发环境。

AI Agent 的核心风险：信任，一个必须解决的技术问题

在讨论解决方案之前，我们必须首先对风险本身有一个清醒的认知。AI Agent 的核心风险，并不仅仅来自于科幻电影里的“AI 觉醒”或恶意攻击，更多的是来自于其工作原理带来的**不确定性和意图的偏差**。

指令的模糊性：人类语言天然存在模糊性。你对同事说“把这个功能上线吧”，他知道这意味着“运行测试、构建镜像、推送到 Staging、观察监控”，而不会真的直接操作生产环境。但 AI Agent 可能会对“上线”这个词，做出最直接、也最危险的字面解释。

上下文的局限性：尽管我们尽力提供上下文，但 AI 的“世界观”永远是片面的。它可能知道要修改 `a.go`，但不知道这个文件正被一个关键的生产服务所依赖，任何一点微小的改动都可能引发雪崩。

统计的随机性：大模型的本质是基于概率生成内容。即便在相同的输入下，它的输出也可能存在细微的差异。这种随机性在带来创造力的同时，也引入了不可预测的风险。

正因为这些风险的存在，我们对 AI Agent 的“信任”，绝不能建立在“它很聪明，不会犯错”的主观期待之上，而必须建立在一套“即便它犯错，也无法造成破坏”的客观技术保障体系之上。Claude Code 的整个安全哲学，就建立在这样一种务实而审慎的思想之上：**默认不信任，逐步授权，全程监督**。它通过权限体系与沙箱机制这两大支柱来实现这一点。

第一大支柱：权限体系——精细到命令级的“立法”

Claude Code 的权限体系，是其安全模型的**第一道、也是最重要的一道防线**。它不像传统的用户权限那样粗放（管理员 / 普通用户），而是构建了一套极其精细的、针对 AI 工具（Tool）的授权模型。

在深入细节之前，我们首先要理解其核心的**权限设计哲学**，它建立在三个核心原则之上：

1. **默认最小权限：**默认情况下，AI 是“只读”的，就像一个只能观察、不能动手的顾问。
2. **显式授权：**任何可能改变你系统状态的操作（写文件、执行命令），都必须经过你的明确批准。
3. **用户主权：**最终的控制权永远在你手中。你可以选择单次批准，也可以通过配置，将你信任的、安全的操作设置为自动批准。

正是基于这套哲学，Claude Code 构建了一套由“**宏观模式**”和“**微观规则**”组成的、强大而灵活的权限体系。

四大权限模式：宏观上设定你的信任级别


首先，Claude Code 为你预设了四种核心权限模式（Permission Modes），让你可以在不同场景下，快速切换整体的安全级别。

模式	核心行为	适用场景	风险等级
default	标准模式，逐一询问。AI默认只能调用只读工具。所有写操作和命令执行都需经过你的逐一批准。	日常开发中最常用的模式，在安全和效率之间取得了最佳平衡。	低（完全可控）
plan	规划模式，只读+计划。行为类似default，但AI更倾向于制定行动计划，而不是直接执行或给出最终答案。	复杂的重构、新功能规划、在动手前需要深度思考的场景。	极低
acceptEdits	自动批准文件编辑。AI可以自动执行文件编辑类操作（Edit, Write），无需你批准。但Bash等高风险命令仍需你批准。	修复大量Linter错误、进行机械性的、可预期的代码格式化或重构。	中等（需谨慎）
bypassPermissions	跳过所有权限提示。AI将无需任何批准，自动执行所有操作，包括Bash命令。即官方文档中的“YOLO模式”。	极高风险，仅应在完全隔离的、无网络访问的容器化环境（如Dev Container）中使用。	极高



【重要】 default 模式是我们最常用的。它在安全和效率之间取得了最佳平衡，既不像 plan 模式那样完全只说不做，也不像 acceptEdits 那样自动修改文件，而是将每一个高风险决策都交由你来把控。

你可以通过 `Shift+Tab` 快捷键在启动的 Claude Code 会话中循环，在 default、plan 和 acceptEdits 模式间切换：



Claude Code v2.0.24

glm-4.6 · API Usage Billing

/root/go/src/github.com/bigwhite/issue2md

> **T**ry "how do I log an error?"

? for shortcuts



Claude Code v2.0.24

glm-4.6 · API Usage Billing

/root/go/src/github.com/bigwhite/issue2md

> **T**ry "how do I log an error?"

[?] accept edits on (shift+tab to cycle)



Claude Code v2.0.24

glm-4.6 · API Usage Billing

/root/go/src/github.com/bigwhite/issue2md

> **T**ry "how do I log an error?"

[||] plan mode on (shift+tab to cycle)


也可以在 `settings.json` 中设置 `defaultMode` 为上面四种模式中的一种。


权限规则（Permission Rules）：微观上为 AI 的行为“立法”

四大模式提供了宏观的控制，而真正的精髓，在于你可以通过 `settings.json` 文件，制定细致入微的**权限规则**。这些规则，就是你为 AI 设定的在这个项目中必须遵守的“法律条文”。

规则的决策流程

规则的决策流程非常清晰：`deny` 拥有最高否决权，其次是 `allow`，最后是 `ask` 和当前权限模式的默认行为。





配置的层次与生效

正如我们在前面基础篇 04 讲提到的，`settings.json` 文件存在于多个层级（企业、用户、项目），并遵循**高优先级覆盖低优先级**的原则。这意味着，你可以在项目级的 `./.claude/settings.json` 中为团队设定一套标准权限，而团队成员也可以在自己的 `~/.claude/settings.json` 中添加个人化的、更严格的规则。

如何查看生效的规则？

在你配置完规则后，如何确认它们已经正确生效了呢？最直接的方法就是使用 `/permissions` 这个内置的 Slash Command。

```
1 > /permissions
```

[复制代码](#)

这个命令会打开一个交互式的界面，清晰地列出当前所有生效的 `allow`、`deny`、`ask` 等规则，这是你调试和验证权限配置的“神器”。

```
> /permissions
```

Permissions: **Allow** Ask Deny Workspace (tab to cycle)
Claude Code won't ask before using allowed tools.

- > 1. Add a new rule...
- 2. Bash(go list:*)
- 3. Bash(go:test:*)
- 4. Bash(npm:run:lint)

```
> /permissions
```

Permissions: Allow Ask **Deny** Workspace (tab to cycle)
Claude Code will always reject requests to use denied tools.

- > 1. Add a new rule...
- 2. Bash(git:push:--force)
- 3. Bash(rm:-rf:*)
- 4. Edit(/docs/**)
- 5. Read(./env*)
- 6. Read(./secrets/**)
- 7. Read(//etc/passwd)
- 8. Read(~/.ssh/*)
- 9. Write(./go.mod)

现在，让我们来看几个核心工具的规则实践：

Read/Edit/Write：控制文件访问，你可以使用类似 `.gitignore` 的语法，精确地控制 AI 能读写哪些文件。这是保护项目敏感信息、防止 AI 意外破坏核心配置的第一道铁索。

 复制代码

```
1 {
2   "permissions": {
3     "deny": [
4       "Read(./env*)",           // 禁止读取任何.env文件
5       "Read(./secrets/**)",    // 禁止读取secrets目录下的所有文件
6       "Read(~/.ssh/*)",        // 禁止读取用户ssh密钥
7       "Read(//etc/passwd)",    // 禁止读取系统敏感文件
```



```

8      "Write(./go.mod)",          // 禁止修改go.mod文件
9      "Edit(/docs/**)"           // 禁止编辑docs目录下的文件（相对于settings.json位置）
10   ]
11 }
12 }

```

【重要】 Read/Edit 规则的路径模式非常讲究：

`path` 或 `./path`：相对于**当前工作目录**。例如：`Read(*.env)` 会匹配当前目录下的 `.env` 文件。

`/path`：相对于 `settings.json` **文件所在目录**。例如：在项目级的 `./.claude/settings.json` 中，`Deny(Read(/config/**))` 会禁止读取项目根目录下的 `config` 文件夹。

`~/path`：相对于**用户主目录**。例如：`Deny(Read(~/.ssh/id_rsa))` 会禁止 AI 读取你的 SSH 私钥。

`//path`：**文件系统的绝对路径**。例如：`Deny(Read(/etc/passwd))` 会禁止 AI 读取系统的密码文件 `/etc/passwd`。请务必区分，错误的路径模式可能会导致你的安全规则失效！

Bash：控制命令执行 Bash 工具是 AI 能力最强的“武器”，也是风险最高的。Claude Code 为其设计了**基于前缀匹配**的规则。

 复制代码

```

1 {
2   "permissions": {
3     "allow": [
4       "Bash(go:test:*)",          // 总是允许执行 `go test` 及其任何子命令
5       "Bash(npm:run:lint)"       // 总是允许执行 `npm run lint`
6     ],
7     "ask": [
8       "Bash(git:commit:*)"       // 执行 `git commit` 时总是询问
9     ],
10    "deny": [
11      "Bash(rm:-rf:*)",           // 绝对禁止 `rm -rf`
12      "Bash(git:push:--force)"    // 绝对禁止强制推送
13    ]
14  }

```

【注意】 这里的 `Bash` 的规则是前缀匹配，而非 `glob` 或 `regex`。这意味着 `Bash(curl:*)` 可以被 `curl -L ...` 轻易绕过。对于需要严格网络控制的场景，`WebFetch` 工具或我们接下来要讲的沙箱机制是更可靠的选择。

`WebFetch` 和 `MCP`：控制外部连接，你可以为可信的网络域和 `MCP` 服务器开启绿色通道。

 复制代码

```

1 {
2   "permissions": {
3     "allow": [
4       "WebFetch(domain:*.golang.org)", // 总是允许访问Go官方文档
5       "mcp__github" // 总是允许使用名为'github'的MCP服务器的所有工具
6     ],
7     "ask": [
8       "mcp__jira__create_issue" // 调用jira服务器的create_issue工具时询问
9     ]
10  }
11 }
```

【注意】 `MCP` 权限规则不支持通配符 `*`。要允许一个服务器的所有工具，请直接使用服务器名，如 `mcp__github`。

通过这套“宏观模式”+“微观规则”的组合，你就拥有了一套强大而灵活的“立法”工具，能够为你的 AI 伙伴量身打造一套清晰、明确、且绝对安全的工作边界。

第二大支柱：沙箱机制——从“操作系统”层面隔离风险

你可能会问，既然我们在上面已经为 AI 制定了如此精细的“法律”（权限体系），为什么还需要为它建造一个“监狱”（沙箱）呢？

答案是：权限体系防范的是“已知的未知”，而沙箱防范的是“未知的未知”。权限体系依赖于我们预先定义的规则，但如果 AI 通过一个我们允许的、看似无害的命令（比如运行一个被恶

意篡改的 npm 脚本）找到了规则的漏洞，或者利用了 `Bash` 前缀匹配规则的局限性呢？

这正是沙箱的用武之地。它不再是应用层面的规则检查，而是深入到**操作系统（OS）**层面，为 AI 的所有高风险操作，构建了一个坚不可摧的“**数字囚笼**”。

准备工作：为你的沙箱安装“地基”

在启用沙箱之前，我们需要确保它的“地基”已经就位。在你的 Ubuntu 环境上，如果你直接在 Claude Code 中运行 `/sandbox`，很可能会遇到和我一样的错误提示：

 复制代码

```
1 > /sandbox
2 | Error: Sandbox requires socat and bwrap. Please install these packages.
```

这个提示告诉我们，Claude Code 的沙箱功能依赖于两个关键的 Linux 工具：

`bwrap` (Bubblewrap)：这是沙箱的核心。它是一个非特权（unprivileged）的容器化工具，能够利用 Linux 内核的**命名空间（Namespaces）**特性，为一个进程创建一个高度隔离的运行环境。

`socat`：一个多功能的网络中继工具。在这里，它被用来创建沙箱内外通信的桥梁，尤其是在网络隔离中扮演关键角色。

在基于 Debian/Ubuntu 的系统上，你可以通过以下命令轻松安装它们：

 复制代码

```
1 sudo apt-get update && sudo apt-get install -y bubblewrap socat
```

安装完成后，你再运行 `/sandbox`，**并不会直接启用沙箱**，而是会进入一个交互式的配置菜单，让你做出一个关键的选择：

```
Claude Code v2.0.24
glm-4.6 · API Usage Billing
/root/go/src/github.com/bigwhite/issue2md

> /sandbox

Sandbox: Manage Config (tab to cycle)

Configure Mode:
> 1. Sandbox BashTool, with auto-allow in accept edits mode
  2. Sandbox BashTool, with regular permissions
  3. No Sandbox (current)

Auto-allow mode: When in accept-edits mode, commands will try to run in the sandbox automatically, and attempts to run outside of the sandbox fallback to regular permissions. Explicit ask/deny rules are always respected.

Learn more: docs.claude.com/sandboxing ( https://docs.claude.com/en/docs/claude-code/sandbox )
```

在macOS上，沙箱则依赖于系统内置的Seatbelt框架，无需额外安装，但同样会面临类似的选择

这个菜单为你提供了两种不同安全级别的沙箱模式，以及一个关闭选项。那么，前两个模式有什么不同，我们应该如何选择呢？

选项 2: Sandbox BashTool, with regular permissions (推荐, 最安全)

含义：启用沙箱，并且所有 `Bash` 命令的执行，都**严格遵循**我们在上一节学习的 `permissions` 体系。这意味着，即使一个 `Bash` 命令在沙箱的安全边界内，如果它没有命中 `allow` 规则，Claude Code 依然会弹窗向你请求批准。

选择建议：对于大多数项目，尤其是涉及生产环境代码、敏感数据或团队协作的场景，**我强烈推荐你选择这个模式**。它为你提供了最坚固的“法律 + 监狱”双重防护。

选项 1: Sandbox BashTool, with auto-allow in accept edits mode (效率优先)

含义：启用沙箱，但是做了一个**效率上的妥协**。当你处于 `acceptEdits` 这个更信任的权限模式时，对于那些在沙箱安全边界内的 `Bash` 命令，Claude Code 将**不再询问你，直接自动执行**。

选择建议：如果你正在一个完全可信的、非关键的个人项目中工作，并且你对沙箱的边界配置非常有信心，希望最大化地提升 AI 的自主工作效率，那么可以选择这个模式。但请务必记住，这在一定程度上牺牲了单次操作的审批权，以换取更高的自动化效率。


在你做出选择后，沙箱就成功启用了。如果你想退出沙箱模式，可以再次执行 `/sandbox`，选择 `No Sandbox` 即可。

现在，让我们再来深入了解它背后的工作原理。

沙箱的核心原理：基于操作系统原语的隔离

与 Gemini CLI 等工具倾向于使用重量级的 Docker 容器来实现沙箱不同，Claude Code 选择了一条更轻、更原生的路径。它利用操作系统级别的安全原语（Linux 上的 `bubblewrap`，macOS 上的 `Seatbelt`）来强制执行文件系统和网络的隔离。

当你启用沙箱后，所有 `Bash` 命令及其子进程都会在一个被严格限制的“数字囚笼”中执行。这个“囚笼”的规则，由一套默认行为和你的 `settings.json` 配置共同决定。



让我们来精确地解读沙箱的两大核心隔离特性：

一是文件系统隔离（Filesystem Isolation）：沙箱对文件系统的访问权限，遵循一套非对称的读写规则：

默认写权限：严格受限。 AI 的写操作（通过 `Bash` 命令）被严格限制在**当前工作目录（CWD）及其子目录**中。任何试图修改 CWD 之外文件的行为，都将被阻断，除非得到你的**明确批准**。这构成了防止 AI“作恶”的核心安全边界。

默认读权限：相对开放。沙箱内的进程默认拥有对几乎整个计算机的只读访问权限。这是一种非常务实的设计，它允许 AI 在需要时，能够像人类开发者一样，去读取系统库、全局配置文件或其他项目的文件来获取解决问题所需的上下文。

可配置性：更精细和推荐的方式是通过我们已经学习的 `permissions` 体系中的 `Read`、`Edit`、`Write` 规则来“立法”。

二是网络隔离（Network Isolation）：沙箱的网络访问则遵循默认拒绝，白名单通行的原则：

代理拦截：所有源自沙箱的网络请求，都会被一个运行在沙箱外部的代理服务器所拦截。

白名单机制：只有在 `permissions` 中通过 `WebFetch(domain:*.example.com)` 规则明确允许的域名，才能通过这个代理。

用户确认：任何对未知域名的访问请求，都会被代理暂停，并弹窗向你请求许可。

全面覆盖：这种隔离适用于 `Bash` 命令及其衍生的所有子进程，确保了网络访问的统一管控。

“安全 YOLO 模式”：沙箱与 `bypassPermissions` 的终极结合

现在，我们可以揭晓 `bypassPermissions`（YOLO 模式）的唯一正确且极其强大的用法了——将其与一个严格配置的沙箱结合。这个流程被称为“安全 YOLO 模式”，它特别适合执行那些高度重复、机械化的、边界清晰的自动化任务。

我们来看一下它的实践流程：

- 配置严格的沙箱规则：**在 `./.claude/settings.json` 中，确保 `sandbox.enabled` 为 `true`，并通过 `permissions` 规则严格限制文件和网络访问。
- 在沙箱内启动 YOLO 模式：**`bash # 确保在项目根目录运行 claude -p "修复这个项目中所有的ESLint错误，直到 npm run lint 命令不再报错为止。完成后，返回'OK'。"--dangerously-skip-permissions`。
- AI 全自动工作：**Claude Code 会在这个受限的“囚笼”里，全速、自主地工作。它想修改项目外的文件？被沙箱的“写权限边界”阻断。它想访问 `evil.com`？被网络代理阻断。它唯一能做的，就是在你为它划定的安全范围内，高效地完成任务。

4. **审查结果：**任务完成后，你通过 `git diff` 审查 AI 所做的所有修改，确认无误后提交。

在这个模式下，我们既利用了 AI 的极致自动化能力，又将其潜在的风险，通过操作系统级的沙箱机制，降到了理论上的最低。

实战：为我们的 Go 项目量身定制一份安全配置

基于我们对 `permissions` 和 `sandbox` 协作关系的最新理解，现在让我们来优化 `issue2md` 项目的 `./.claude/settings.json` 文件或 `settings.local.json` 文件。

`./.claude/settings.json`

 复制代码

```
1 {
2   "permissions": {
3     "allow": [
4       "Read(go.mod)",
5       "Read(Makefile)",
6       "Read(README.md)",
7       "Grep",
8       "Glob",
9       "LS",
10      "Bash(go:version)",
11      "Bash(go:list:*)",
12      "Bash(go:build:*)",
13      "Bash(go:test:*)",
14      "Bash(gofmt:*)",
15      "Bash(goimports:*)",
16      "Bash(golangci-lint:run:*)",
17      "WebFetch(domain:pkg.go.dev)",
18      "WebFetch(domain:*.golang.org)",
19      "WebFetch(domain:github.com)",
20      "Bash(go list:*)",
21      "Bash(go version:*)"
22    ],
23    "deny": [
24      "Read(./env*)",
25      "Read(~/.ssh/**)",
26      "Read(/etc/passwd)",
27      "Bash(rm:*)",
28      "Bash(git:push:*)"
29    ],
30    "ask": [
```

```
31     "Write",
32     "Edit",
33     "MultiEdit",
34     "Bash(go:get:*)",
35     "Bash(go:mod:tidy)",
36     "Bash(git:add:*)",
37     "Bash(git:commit:*)"
38 ],
39     "defaultMode": "default"
40 },
41     "sandbox": {
42         "autoAllowBashIfSandboxed": false,
43         "enabled": true
44     }
45 }
```

让我们来解读这份优化后的配置

permissions 部分（立法）

allow：我们为无害的 **Bash** 命令（如测试、格式化）和必要的文档网站（**WebFetch**）开放了绿色通道。特别注意，我们不仅允许了 Go 的官方文档和代理网站，还加入了 github.com。这是因为 Go 模块的依赖解析经常需要回源到 GitHub 等代码托管平台。

ask：我们在所有“改变世界”的操作上，都设置了“红绿灯”，包括修改代码、改变依赖、记录历史。

deny：我们用最严厉的规则，划定了**绝对的“禁区”**，包括读取敏感文件和执行破坏性 **Bash** 命令。

sandbox 部分（执法）

enabled: true：我们强制所有 **Bash** 命令都在沙箱中运行。

autoAllowBashIfSandboxed: false：我们选择了最安全的模式，明确要求沙箱内的 **Bash** 命令**依然要接受 permissions 体系的审查**，实现了安全双保险。

这份配置，就是我们为 `issue2md` 项目量身打造的、严格遵循官方文档的“**法律 + 监狱**”双重保障体系。

本讲小结

今天，我们深入了 AI 原生开发最底层的基石——安全与信任。我们不再将 AI 视为一个需要时时警惕的“黑盒”，而是学会了如何通过技术手段，将其塑造为一个能力边界清晰、行为可预测、最终值得信赖的开发伙伴。

首先，我们分析了 AI Agent 的**核心风险**，并明确了 Claude Code 的安全哲学：**默认不信任，逐步授权，全程监督**。接着，我们深入学习了 Claude Code 安全模型的**第一大支柱：权限体系（Permissions）**。它如同“**应用层的法律**”，通过 `allow`, `deny`, `ask` 规则，为 AI 的所有工具调用（包括 `Read`, `Write`, `Bash` 等）制定了精细的行为准则。

然后，我们探讨了安全模型的**第二大支柱：沙箱机制（Sandboxing）**。它如同“**操作系统层的物理边界**”，主要为高风险的 `Bash` 命令提供了一个默认隔离的文件系统和网络环境，是安全的最后一道防线。

最后，我们掌握了“**安全 YOLO 模式**”这一终极自动化实践，即通过将 `bypassPermissions` 模式与一个严格配置的沙箱结合，实现既高效又安全的无人值守 workflow。请记住，**安全不是效率的敌人，而是效率可持续的保障**。掌握了权限与沙箱的协同配置，你就拥有了驾驭 AI 这匹“千里马”的“缰绳”与“赛道”，可以放心地让它驰骋。

然而，我们今天的讨论，还只是解决了安全问题的一半。我们确保了 AI 在“行动前”是可控的。但如果一个操作，是我们自己批准的，但执行后却发现结果并非我们所想，我们又该如何快速、无痛地“反悔”呢？

这就是我们下一讲要解决的问题：**Checkpointing**。我们将学习如何获得让 AI“时光倒流”的超能力，为 AI 的所有行动，再上一道“事后可追溯、可反悔”的终极保险。

思考题

假设你要为一个典型的前端项目（使用 React 和 npm）设计一套完整的

`./.claude/settings.json` 安全配置。这份配置需要同时兼顾安全性和日常开发效率。

请你思考并设计这份 `settings.json`，至少需要包含 `permissions` 和 `sandbox` 两个顶级字段。

在你的设计中，请特别回答以下几个问题：

1. 在 `permissions` 的 `allow`, `ask`, `deny` 中，你会分别放入哪些与 `npm`、`node`、`git` 相关的 `Bash` 工具规则？（例如，`npm install`, `npm test`, `npm run build` 等应该如何配置？）
2. 你会如何配置 `sandbox` 块？特别是 `enabled` 和 `autoAllowBashIfSandboxed` 这两个选项，你会如何取舍？为什么？
3. 为了让 `npm install` 能够在网络隔离的沙箱中成功运行，你需要在 `permissions` 的 `allow` 中添加哪条 `WebFetch` 规则？（提示：`npm` 的默认源地址是什么？）

欢迎在评论区分享你的完整 `settings.json` 配置方案和设计思路。这个练习将帮助你将本讲学到的两大安全支柱，融会贯通地应用到真实的工程场景中。如果你有所收获，也欢迎你分享给其他朋友，我们下节课再见！

AI智能总结

1. AI Agent的核心风险包括指令的模糊性、上下文的局限性和统计的随机性，需要建立在一套客观技术保障体系之上来解决信任问题。
2. Claude Code的安全哲学建立在默认不信任、逐步授权、全程监督的思想之上，通过权限体系与沙箱机制来实现。
3. Claude Code的权限体系建立在默认最小权限、显式授权和用户主权的核心原则之上，构建了一套由“宏观模式”和“微观规则”组成的、强大而灵活的权限体系。
4. Claude Code为用户预设了四种核心权限模式，包括`default`、`plan`、`acceptEdits`，让用户可以在不同场景下快速切换整体的安全级别。
5. 沙箱机制是为了防范“未知的未知”，在操作系统层面隔离风险，为AI的高风险操作构建了一个坚不可摧的“数字囚笼”。
6. 沙箱功能依赖于两个关键的Linux工具：`bwrap`（Bubblewrap）和`socat`，并提供了两种不同安全级别的沙箱模式供选择。
7. “安全YOLO模式”是将`bypassPermissions`与严格配置的沙箱结合，实现高效且安全的无人值守工作流。
8. 下一讲将解决Checkpointing问题，学习如何获得让AI“时光倒流”的超能力，为AI的所有行动提供“事后可追溯、可反悔”的终极保险。

全部留言 (14)

最新 精选



jsSoftware

2025-12-16 来自美国

```
{
  "permissions": {
    "allow": [
      "Bash(npm:install)",
      "Bash(npm:ci)",
      "Bash(npm:run:build)",
      "Bash(npm:run:test)",
      "Bash(npm:run:lint)",
      "Bash(npm:run:lint:fix)",
      "Bash(npm:run:prettier)",
      "Bash(yarn:install)",
      "Bash(git:show)",
      "Bash(git:diff)",
      "Bash(git:clone)",
      "Bash(git:remote:-v)",
      "Bash(node:--version)",
      "Bash(npm:--version)",
      "Bash(yarn:--version)",
      "Bash(npx:--help)",
      "Bash(ls)",
      "WebFetch(domain:registry.npmjs.org)",
      "WebFetch(domain:registry.npm.taobao.org)"
    ],
    "ask": [
      "Bash(npm:publish)",
      "Bash(npm:unpublish)",
      "Bash(npm:deprecate)",
      "Bash(npm:audit:fix)",
      "Bash(npm:cache:clean)",
      "Bash(yarn:publish)",
```



```
"Bash(yarn:upgrade)",
"Bash(yarn:upgrade-interactive)",
"Bash(yarn:build)",
"Bash(yarn:add)",
"Bash(yarn:remove)",
"Bash(git:fetch)",
"Bash(git:pull)",
"Bash(git:commit)",
"Bash(git:commit:-m)",
"Bash(git:commit:--amend)",
"Bash(git:push)",
"Bash(git:push:--force)",
"Bash(git:push:--force-with-lease)",
"Bash(git:reset)",
"Bash(git:reset:--hard)",
"Bash(git:revert)",
"Bash(git:rebase)",
"Bash(git:cherry-pick)",
"Bash(git:tag)",
],
"deny": [
  "Bash(rm)",
  "Bash(rm:-rf)",
  "Bash(rmdir)",
  "Bash(sudo)",
  "Bash(su)",
  "Bash(passwd)",
  "Bash(useradd)",
  "Bash(userdel)",
  "Bash(usermod)",
  "Bash(reboot)",
  "Bash(shutdown)",
  "Bash(halt)",
  "Bash(poweroff)",
  "Bash(systemctl)",
  "Bash(service)"
]
},
```

```
"sandbox": {  
  "enabled": true,  
  "autoAllowBashIfSandboxed": false  
}
```

作者回复: 🍊



👍 6



龍蝦 🍷

2026-01-15 来自浙江

"Bash(rm:-rf:*)", // 绝对禁止 `rm -rf`

Bash 的规则是前缀匹配，是不是意味着如果 AI 执行 `rm / -rf`，就可以绕过了？

作者回复: 好像的确存在这种可能。如果要更加安全，可以直接禁用危险命令本身，不加参数限制。

例如: `deny: ["Bash(rm:*)"]`。这意味着任何形式的 `rm` 都被禁止，无论参数怎么写。



👍 2



破烂pan

2025-12-31 来自北京

win11 的WSL中的Ubuntu24.04是不支持 `/sandbox` 命令的，设计如此。。

作者回复: 🍊



👍 1



Ray

2025-12-22 来自山东

请教下老师，权限模式中的Delegate mode的用法能讲下吗

作者回复: 这个模式应该是新增的吧，虽然存在，但claude code官方似乎也没有这个模式的详细介绍。目前我也只是用default、plan或accept edits这三种。等后续有详尽文档，我再考虑通过加餐文章模式介绍吧[手动抱拳]。



👍 1



Ray

2025-12-16 来自山东

文中, `./.claude/settings.json`文件的配置里,
`"autoAllowBashIfSandboxed": true`,是不是应该为false

作者回复: 文中的上下文: 我们正在构建一个“量身定制的权限配置”, 目的是精细化控制风险。虽然理论上“沙箱”是安全的, 但作为最佳实践, 我们依然希望对 Bash 命令 (尤其是涉及网络或高风险操作的) 保持知情权和审批权。

因此, 在这份强调“安全第一、逐步授权”的配置中, 将其设置为 false (或者直接移除该字段, 默认为 false) 是更严谨、更符合本讲“戴上安全镣铐”思想的做法。非常感谢你的提问!



1



侠客行

2025-12-08 来自海南

```
{
  "sandbox": {
    "enabled": true,
    "autoAllowBashIfSandboxed": false
  },
  "permissions": {
    "allow": {
      "bash": [
        "^ls -[a-zA-Z]*$",
        "^cat .*",
        "^pwd$",
        "^echo .*",
        "^git status$",
        "^git log.*",
        "^git diff.*",
        "^node -v$",
        "^npm -v$",
        "^npm run test$",
        "^npm run lint$"
      ],
      "WebFetch": [
        "https://registry.npmjs.org/*",
```

```
    "https://registry.yarnpkg.com/*"
  ],
},
"ask": {
  "bash": [
    "^npm install.*",
    "^npm ci.*",
    "^npm run build",
    "^npm start",
    "^git add .*",
    "^git commit.*",
    "^git push.*"
  ]
},
"deny": {
  "bash": [
    "^npm publish.*",
    "^rm -rf /$",
    "^curl .* | bash",
    "^wget .* | bash"
  ]
}
}
```

作者回复: 👍



1



s(t)

2026-01-12 来自上海

沙箱模式不太理解

- 1.文章里说cwd外的写操作都会被限制，除非用户批准，最终结果不还是我批准了会执行吗？和非沙箱有啥区别？
- 2.还是说沙箱里面的文件系统和真实文件系统是隔离的，就算我有危险操作了也没事不会影响真实的。那我操作完沙箱里面的文件，要生效，就还是走 git 提交那一套，然后在真实环境拉下来？

作者回复: Claude Code 的默认沙箱是逻辑沙箱, 它不是虚拟机或容器。它只是一个“权限检查器”。它在工作时会帮你拦了一下某些修改操作。如果你不批准, 操作就不会发生; 如果你批准了 (即便是 `rm -rf /`), 它也会真删。



李二木

2026-01-04 来自四川

manus的 运行环境是怎么设计的啊, 是启动一个docker环境吗

作者回复: 不了解, 有知道的小伙伴儿可以分享一下。



塞万提斯

2026-01-03 来自北京

配置文件中"`autoAllowBashIfSandboxed`": `true`,
后面解释

`autoAllowBashIfSandboxed`: `false`: 我们选择了最安全的模式, 明确要求沙箱内的 Bash 命令依然要接受 `permissions` 体系的审查, 实现了安全双保险
矛盾了, 是不是配置文件中没改过来?

作者回复: 是的, 这里确实是一个笔误, 感谢你的细心指正!

文中的逻辑是: 我们希望“最安全”, 所以即使在沙箱里, 也不应该自动放行, 而应该继续接受 `permissions` 规则的检查。

正确的配置应为: "`autoAllowBashIfSandboxed`": `false`。这样就保持与后面的说明一致了。

稍后让编辑老师修改一下。



jarvis

2025-12-14 来自上海

claude code `--dangerously-skip-permissions`, 基本上都直接这么用了,,,,,

作者回复: 还是有一定风险的。我看一些claude code社区的人反馈, 真有删除用户目录的情况。真不建议这么做。

如果不是全自动处理, 而是采用交互模式, 每一步还要注意审核cc的输出结果。这一点也非常重要。

